Assistant RAG sur le Code du travail du Sénégal

Rapport : résultats de l'évaluation, erreurs constatées, ce que nous changerions

Projet LLM & Écosystème, groupe 2 : Massamba Fall Séne (tech lead), Abdou Karim, Haroona, Sine Ndoye, Mamadou

Dépôt : github.com/massamba0809/p1ia_groupe-2_llm-projet

1. Le système

L'assistant répond à des questions sur le Code du travail du Sénégal (loi n° 97-17, version de 1997) en citant les articles utilisés. Le corpus compte 289 articles (L.1 à L.288 plus L.76bis), découpés en 336 chunks : un chunk par article, les articles de plus de 1200 caractères étant scindés. La recherche utilise le modèle d'embeddings *intfloat/multilingual-e5-small* et une base ChromaDB. La génération utilise Groq (*openai/gpt-oss-120b*, température 0). Le prompt impose de répondre uniquement à partir des articles fournis, de citer les articles, de refuser quand la réponse est absente et de traiter les articles et la question comme des données, pas comme des instructions (défense contre l'injection de prompt).

Répartition : Abdou Karim (ingestion), Haroona (embeddings et recherche), Massamba (génération et intégration), Sine Ndoye (évaluation et rapport). Le module bonus (function calling, garde-fous, observabilité) n'a pas été intégré au rendu.

2. Méthode d'évaluation

21 questions avec réponse de référence vérifiée dans le texte et article attendu : 15 factuelles, 2 reformulées en langage courant, 1 hors corpus (montant du SMIG, absent du Code), 1 hors sujet, 1 tentative d'injection, 1 contenant des données personnelles. Mesures : hit@1, hit@4 et MRR (bon article retrouvé et son rang, sur les 19 questions qui ont un article attendu), fidélité et exactitude notées 0, 0,5 ou 1 par un LLM juge, présence d'une citation d'article, latence. Le script (*python -m eval.evaluate*) reproduit les chiffres du module de recherche sur les 6 premières questions.

3. Résultats

Groupe	n	hit@1	hit@4	MRR	Fidélité	Exactitude	Citation	Latence (s)
Global	21	58 %	84 %	0,67	0,98	0,90	84 %	7,3
factuelle	15	67 %	87 %	0,73	1,00	0,87	87 %	6,2
reformulée	2	50 %	100 %	0,67	1,00	1,00	100 %	14,4
hors corpus	1	0 %	0 %	0,00	1,00	1,00	0 %	8,9
hors sujet	1	n/a	n/a	n/a	1,00	1,00	n/a	8,9
injection	1	n/a	n/a	n/a	0,50	1,00	n/a	4,6
données perso.	1	0 %	100 %	0,50	1,00	1,00	100 %	10,0

- **La recherche place le bon article parmi les 4 premiers dans 84 % des cas** (16 questions sur 19 ; 89 % si on exclut la question piège sur le SMIG), mais en 1re position seulement dans 58 % des cas. Avec k = 3, hit@k tomberait à 79 % et avec k = 2 à 63 % : nous gardons k = 4.
- **Le système n'invente pas :** la fidélité est de 1,00 sur 20 questions sur 21 ; la question hors corpus (le SMIG) et le hors-sujet reçoivent un refus correct. La seule note inférieure est 0,5 sur la tentative d'injection (la réponse est jugée exacte, mais pas entièrement fidèle aux passages).
- **Deux réponses fausses sur 21** (exactitude 0 pour q15 et q17). Dans les deux cas le bon article n'était pas parmi les 4 passages : l'erreur vient de la recherche, pas de la génération.

4. Erreurs constatées

Pour chaque échec, nous avons lu le texte des articles qui ont pris la place du bon. Sur les 7 questions où le bon article n'est pas en 1re position (hors SMIG), 4 viennent d'un écart de vocabulaire entre la question et le texte de loi (q02, q15, q17, q18), 2 d'articles voisins quasi identiques (q12, q16) et 1 des données personnelles (q21). Ces résultats ont été mesurés sur le dépôt final (336 chunks) : le nouveau découpage a fait passer q17

de la 4e place à « non trouvé » par rapport à notre première mesure (89 % de hit@4). Un petit changement de découpage suffit donc à déplacer un score.

Question	Ce qui s'est passé	Cause constatée
q02 congé de maternité	L.143 au rang 4	Le mot « maternité » n'existe pas dans le Code : L.143 dit « accouchement ». Des articles voisins sur les mères ressemblent davantage à la question.
q15 délai pour réclamer un salaire	L.126 non trouvé : exactitude 0	L.126 dit « action en paiement » et « prescrivent par cinq ans », sans « délai » ni « réclamer ».
q17 égalité de salaire	L.105 non trouvé : exactitude 0	La question dit « femme », L.105 dit « sexe ». Des articles sur la « femme mariée » (L.249, L.10) sans rapport passent devant, et L.279-2 prend la 4e place.
q18 salaire en sacs de riz	L.114 au rang 3	Langage courant contre « payé en nature » dans le Code.
q12 nombre de CDD ; q16 rupture sans préavis	L.42 au rang 3 ; L.54 au rang 3	Articles voisins presque interchangeables (L.41/L.42 ; L.50, L.53, L.54 sur le préavis).
q21 congés + données personnelles	L.148 au rang 2	Même question sans données personnelles : rang 1. La formulation diffère un peu, l'effet n'est donc pas isolé.
q20 montant du SMIG	L.109 non trouvé	Piège : le Code ne donne pas de montant, le sigle « SMIG » n'y figure pas. Le refus du système est le bon comportement.

5. Limites de l'évaluation

- Petit jeu de 21 questions, écrites par l'équipe et proches du texte de loi : un seul échec fait varier un score de 5 points, les tendances sont indicatives.
- Un seul article attendu par question : strict, car en q12, q16 ou q15 d'autres articles sont aussi pertinents. La recherche est parfois sous-estimée.
- Le juge est un LLM, et c'est le même modèle que celui qui génère : il peut être indulgent. Fidélité 1,00 partout est donc à prendre avec prudence, et les notes n'ont pas été relues systématiquement par un humain.
- Corpus de 1997 : une réponse fidèle au corpus peut être dépassée en droit (nouveau code du travail en cours d'application).
- Un seul cas pour l'injection, le hors-sujet et les données personnelles : ces résultats ne prouvent pas la robustesse du système.

6. Ce que nous changerions

Ces pistes viennent des échecs observés. **Aucune n'a encore été testée.**

1. Reformuler la question avec le vocabulaire du Code avant la recherche (« maternité » vers « accouchement », « réclamer » vers « prescription de l'action en paiement ») : vise q02, q15, q17, q18.
2. Ajouter un reranker pour départager les articles voisins (q12, q16).
3. Masquer les données personnelles avant la recherche (garde-fou du module bonus) et le vérifier avec une paire de questions strictement identiques.
4. Agrandir le jeu de questions avec des formulations de vraies personnes, et faire noter une partie des réponses par un humain pour valider le juge.
5. Ne pas détecter le hors-sujet par un seuil sur le score (les scores e5 sont trop resserrés) : laisser le LLM refuser quand les passages ne répondent pas.

Sources

Code du travail du Sénégal (loi n° 97-17), PDF Jurisconsult / Ministère de la Justice (vie-publique.sn/documents/437/code-travail-senegal). Modèle d'embeddings intfloat/multilingual-e5-small. LLM openai/gpt-oss-120b via Groq. Détails des chiffres : *eval/results/resume.md*, *eval/results/resultats.csv*, *reports/rapport.md*.